

项目经历

AIResume——AI 简历分析与模拟面试平台（个人全栈项目）

技术栈：FastAPI、PostgreSQL 16（pgvector）、Redis、SQLAlchemy 2、Celery、Vue 3、Vite、LangChain 0.3、Ollama（nomic-embed-text）

项目简介：一个集成用户注册登录、PDF 简历上传解析、AI 智能分析报告与多轮文字模拟面试的全链路 AI 应用平台。针对 AI 输出不可控、简历解析易翻车与长耗时任务阻塞三大痛点，采用“统一 AI 封装层 + JSON 结构化校验 + 异步任务化 + RAG 混合检索”的整体架构，实现从简历上传到智能评估、模拟面试与知识库问答的一体化服务。

- 搭建基于 pgvector 的知识库问答系统，实现“向量检索 + jieba 分词 BM25 词法检索 + RRF 融合”的混合检索，在 49 题黄金问答集上 top-1 命中率由 71.4% 提升至 87.8%（top-5 达 100%），且无一题回退。
- 基于 LangChain 0.3 构建 ReAct Agent，落地 11 个业务工具（知识检索、简历查询、面试历史、岗位匹配、题目生成、答案点评等），统一归属过滤防止个人数据越权，工具路由评测 33/33 达 100% 准确率。
- 基于 SSE 流式协议实现 AI 逐字输出与 Agent 工具调用过程可视化，配套会话快照守卫与 abort 句柄，消息全量落库，实测单次问答输出 500+ 流式分片，中断后刷新页面即可恢复会话。
- 引入 Celery + Redis 将简历解析、知识库入库等长耗时任务全链路异步化（幂等重试），前端实时展示任务进度；基于 Redis 令牌桶实现每日限额与限流，遏制恶意请求刷爆 AI API 调用成本。
- 封装 OpenAI 兼容协议层，内置 JSON 输出结构化校验与失败自动重试（最多 2 次），提示词带版本号留档，切换模型仅需修改 3 行配置，保证 AI 输出结构化可控、分析报告可对比追溯。
- 完成 77 项安全审计修复（含 2 项 P0 横向越权漏洞），统一匿名/登录双条件归属校验杜绝越权访问；264 个 pytest 用例全绿、服务层覆盖率 89%，CI 流水线（代码检查 → 数据库迁移 → 测试 → 前端构建）全绿。
- 设计数据库快速失败机制，连接异常统一转为 503 友好提示且不泄露内部细节，实测停库 5.3 秒返回（修复前挂起 60 秒以上），故障恢复后 0.36 秒自动回归正常。